赛题介绍

- **赛题背景**

随着社会的发展，人口结构、人口流动情况和就业状况等方面在不断变化，各种人口数据如人口普查、户口信息、迁移信息等也在大量积累。
因此，利用这些数据进行人口分析和预测具有重要的实际意义。

- **赛题任务**

本次竞赛旨在通过参赛者对给定的大量人口数据进行特征工程、机器学习算法构建和模型优化，以实现人口分析和预测的任务。具体包括以下两个阶段任务：

1.初赛 A 榜
给定多个城市近几年的人口数据，包括年龄、职业、收入等特征，分析每个城市的特点和规律，利用算法构建人口预测模型，预测给定各个城市 2023 年的总人口数。

2.初赛 B 榜
A 榜评测结束后，排行榜 top50%的团队晋级初赛 B 榜评测；给定多个城市近几年的人口数据，利用算法构建人口预测模型，预测给定各个城市 2023 年的总人口数，B 榜 TOP5 团队经复现审核后入围决赛。

数据说明

数据文件夹包含 7 个文件，依次为：

文件名	文件内容	字段
人口规模.xlsx	城市人口规模信息	pr_Population —— 常住人口规模
		r_Population—— 户籍人口规模
城镇化率.xlsx	城市的城镇化率	urbanizationRate —— 城镇化率
年龄结构.xlsx	城市人口的年龄结构	0-14 —— 0-14 岁人口规模
		15-64 —— 城市 15-64 岁人口规模
		65+ —— 城市 65 岁及以上人口规模
人口密度.xlsx	城市的人口密度	populationDensity - 人口密度
就业信息.xlsx	城市的就业情况	unemploymentRate —— 失业率
		employeesNumber —— 从业人员数
		newlyEmployedPeople —— 城镇新增就业人员数
		threeIndustriesEmployed—— 三次产业就业人员数

工资水平.xlsx	城市就业人员的工资水平	averageWage —— 职工平均工资
		unpu_ averageWage —— 城镇非私营单位平均工资
人民生活水平.xlsx	城市人民生活水平指标	disposableIcome —— 人均可支配收入
		consumptionExpenditures —— 人均消费支出
		towner_ ConsumptionExpenditures 城镇居民消费支出
		rural_ConsumptionExpenditures 农村居民消费支出
		towner_disposableIcome 城镇居民人均可支配收入
		rural_disposableIcome 农村居民人均可支配收入

本赛题禁止使用外部数据

提交要求

模型结果提交

参赛者以 csv 文件格式提交到大数据竞赛平台，平台进行在线评分，实时排名。目前平台仅支持单文件提交，即所有提交内容需要放在一个文件中；
submission.csv 文件，字段如下：

字段名	类型	取值范围	字段解释
city_id	str	-	城市编码
year	Num	-	年份
pred	Num	-	人口数据值

算法源程序提交

参赛者需要以 docker、压缩包等方式封装源代码、模型、数据进行提交，提交文件命名：Dockerfile。

决赛阶段方案压缩包提交

参赛者将所需要的各类文档、源代码等压缩打包后，通过大数据竞赛平台提交，主办方进行下载后评审，或者通过平台分发给各位专家进行评审。

评测标准

采用均方误差（mean squared error）评估模型的预测精度，均方误差越小表示预测效果越好。

MSE 为本赛题的评测参考标准，排行榜的分数计算依据为：score =1/(1+MSE)

常见问题说明

1、数据预处理：赛题提供的数据来自多个数据表格，需要进行数据预处理和清洗，以方便后续的特征工程、建模和评估。可以使用 Pandas 等库对数据进行读取、合并、过滤、填充、转换等操作。

2、特征工程：赛题中的数据包含多种不同类型的特征，例如数值型、分类型、时间序列型等。选手可以根据业务理解和数据探索的结果，构建新的特征或对现有特征进行组合、聚合、编码等处理，以提高模型的预测能力。

3、模型选择：赛题要求参赛选手构建一个预测模型，可以选择多种机器学习算法或深度学习网络来实现。选手应该了解各种算法的优缺点、适用场景和参数设置等信息，综合考虑模型的复杂度和泛化能力，并根据赛题评分标准选择最合适的模型。

4、模型训练：在构建好模型之后，选手需要对模型进行训练和调优，以获得最佳的性能表现。可以使用交叉验证、网格搜索等技术进行模型选择和参数优化，同时要注意防止过拟合或欠拟合的情况。

5、模型评估：赛题要求选手使用均方根误差（RMSE）作为评价指标，可以使用 Sklearn 等库来计算 RMSE。此外，选手还可以使用其他评价指标来全面评估模型的性能，例如平均绝对误差、R2 分数、分类准确率等。

6、提交格式：在提交结果时，参赛选手需要按照赛题要求将模型预测结果保存为 CSV 文件，并按照指定的格式进行命名和打包。此外，还需要遵守提交时间、文件大小和提交次数等限制，提前做好规划和时间安排。

7、其他建议：建议选手在参赛之前先阅读赛题说明、数据描述、评分标准等内容，对赛题有一个初步的了解和认识。在比赛过程中，选手应该注意数据的质量、特征的重要性、模型的可解释性等问题，及时反馈和调整。同时，也可以积极参与赛题讨论、组队合作、经验分享等活动，以提高自身的素质和水平。